Лабораторная работа № 3

Сбор данных через REST API: код и no-code

Выполнил: Вшивков К. И., группа ПМИ-3-2025
Вариант 6. Страны: население, регион, экономические показатели
Дата: 2 ноября 2026 года

1. Цель работы

Получить данные через REST API, преобразовать JSON в таблицу, объединить сведения из двух источников и сравнить сбор на Python и в n8n.

Собраны население и ВВП на душу населения за 2020-2022 годы. Основной источник - World Bank API. Столицы добавлены из CountriesNow. Итоговая таблица содержит **651 строку по 217 странам и экономикам**. Одна строка соответствует стране за один год.

2. Источники данных, вариант 6

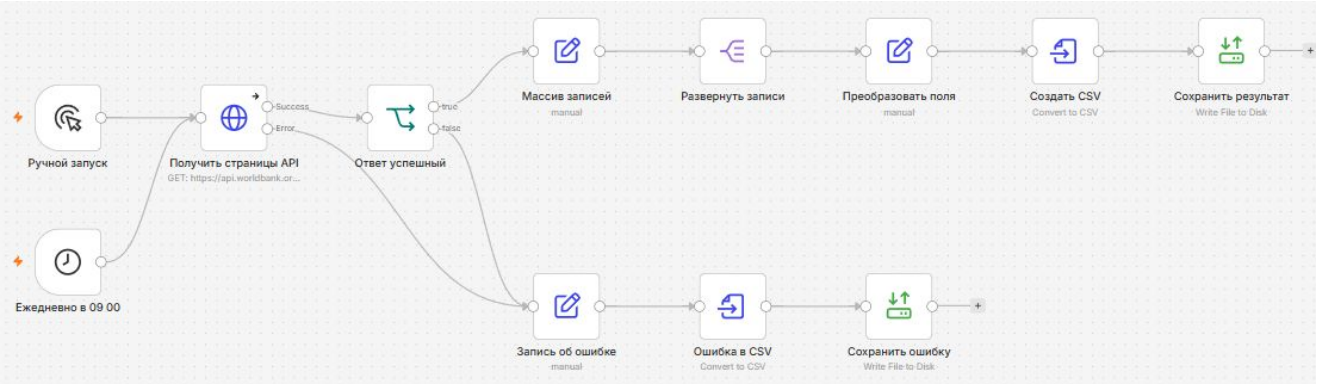
Параметр	World Bank	CountriesNow
Адрес и версия	api.worldbank.org/v2	countriesnow.space/api/v0.1
Эндпоинты	/country; /country/all/indicator/SP.POP.TOTL; /country/all/indicator/NY.GDP.PCAP.CD	/countries/capital
Авторизация	Не требуется	Не требуется
Пагинация	page, per_page; число страниц и записей в ответе	Один справочник
Даты	Год в поле date	Дат нет
Ключ	Код страны, год и показатель	ISO3
Лимит запросов	Числовой лимит в использованной документации не указан	Числовой лимит не указан

Ответы приходят в JSON. Между запросами выдерживается пауза 0,6 секунды. Заголовок Retry-After учитывается при наличии.

3. Схема обработки

API → JSON → таблица → объединение по коду страны → проверки → CSV.

Вложенные поля раскрываются через json_normalize. Региональные агрегаты исключаются по справочнику стран. Столицы присоединяются по коду страны через left merge. Число строк до и после объединения проверяется.



4. Реализация на Python

Использована requests.Session с User-Agent, Accept и таймаутами. Проверяются статус и Content-Type. Для 429 и 5xx выполняются до трёх повторных попыток с увеличением задержки и случайной добавкой. Остальные ошибки выводятся сразу.

Данные запрашиваются по 100 записей на странице. Сбор заканчивается по пустому ответу или числу записей из метаданных. Параметры max_records и max_pages ограничивают объём. Ответы сохраняются в data_raw.jsonl, сведения о запросах - в collection_log.csv.

Массив data справочника столиц раскрывается через record_path и meta. В state.json сохраняются последний год, накопленные наблюдения и результаты запусков. Если состояния нет, загружается весь период. При повторном запуске запрашивается последний сохранённый год. Результат записывается в data_clean.csv.

5. Качество данных

Поле	Полнота, %
Код страны	100.00
Название страны	100.00
Регион	100.00
Группа дохода	100.00
Столица	99.08
Год	100.00
Начало годового периода, UTC	100.00
Население	100.00
Население, млн	100.00
ВВП на душу населения, долл. США	96.62

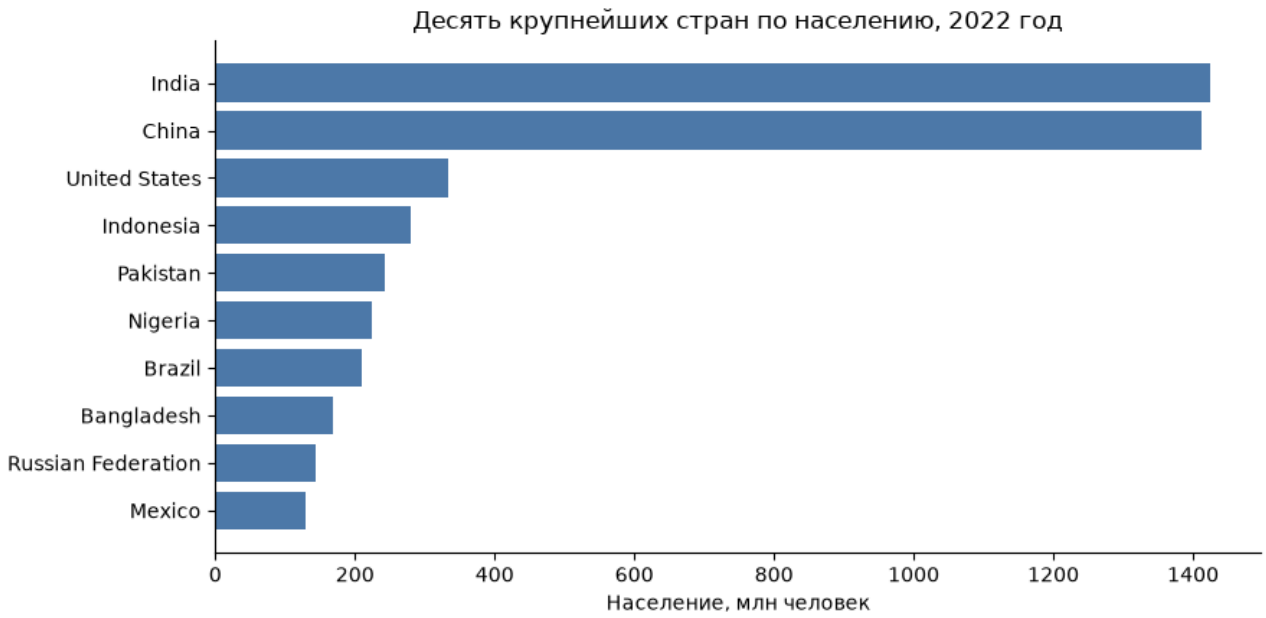
Проверены полнота полей, дубликаты по стране и году, численность населения, неотрицательность ВВП и диапазон годов. Нарушений не обнаружено. Поле period имеет тип datetime с UTC.

До и после объединения осталось 651 строка, совпадения по справочнику столиц найдены для 645 строк. Столицы не сопоставились для ASM и CHI. По правилу 1,5 IQR выделено 50 выбросов ВВП на душу населения; автоматически они не удалялись.

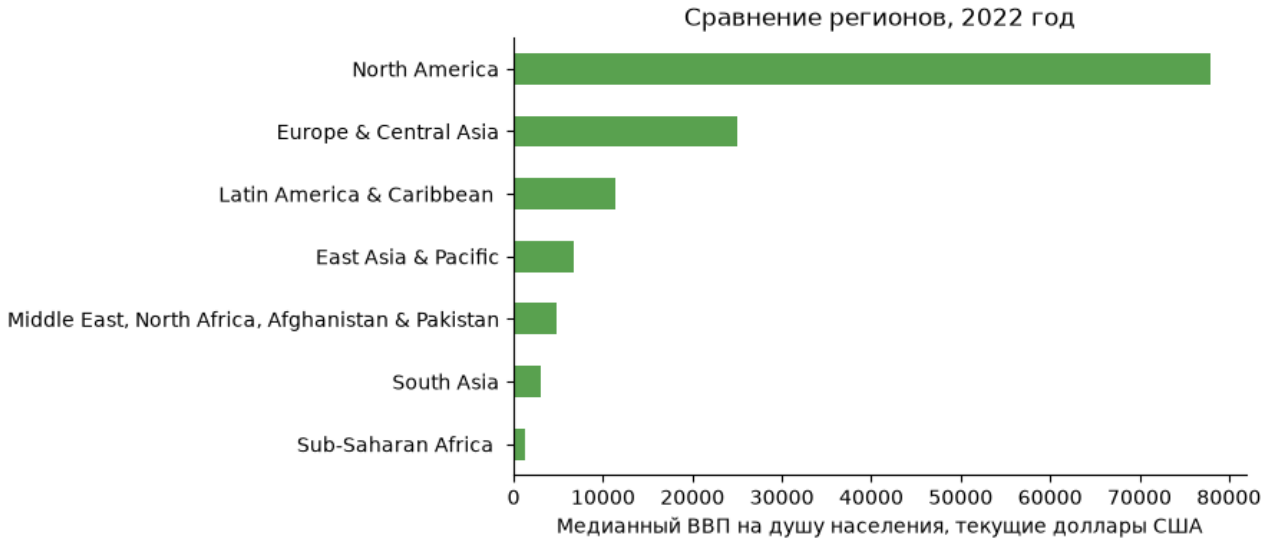
6. Повторный запуск

В сохранённом запуске блокнота от 02.11.2026 сбор с готовым состоянием занял 15.366 с, повторный запуск - 7.196 с. Каждый выполнил 10 запросов и получил 532 наблюдения за последний год. Новых и изменённых наблюдений - 0. В обоих случаях осталось 651 строка без дубликатов.

7. Анализ данных



Наибольшее население за 2022 год: India - 1425.4 млн, China - 1412.2 млн, United States - 334.0 млн.



Сравнение регионов по медианному ВВП на душу населения за 2022 год. Медиана рассчитана по странам с известным значением.

8. Сбор данных в n8n

В nocode/workflow.json сохранён сценарий сбора населения десяти стран за 2020-2022 годы. Получены 30 записей с трёх страниц по 10 записей.

После проверки HTTP-статуса массив разворачивается в строки. Поля переименовываются, год переводится в число и рассчитывается население в миллионах. Результат сохраняется в nocode_result.csv. Ошибка передаётся в отдельную ветку и записывается в error_log.csv.

Предусмотрены ручной запуск и расписание на 09:00 по Перми. Расписание выключено до публикации workflow. Для запуска нужно импортировать workflow.json и нажать Execute workflow. Схема и скриншоты выполнения находятся в папке nocode.

9. Сравнение подходов

В Python получена 651 строка, в n8n - упрощённая выборка из 30. Для сравнения выбраны те же десять стран и пять общих полей. Все значения совпали.

В таблице приведены сохранённые контрольные замеры от 25.10.2026. Время выполнения измерялось отдельно на одинаковых 30 записях и трёх страницах.

Критерий	Python	n8n
Число записей в сравнении	30	30
Время одного прогона, с	2.853	2.106
Пагинация	Функция, 3 страницы	HTTP Request, 3 страницы
Ошибки и повторы	Журнал; повторы 429/5xx	Ветка ошибки; без повторов
Воспроизводимость	Код, блокнот, requirements.txt	Экспорт workflow и Compose
100 запусков в месяц	0 руб. за ПО и API	0 руб. за ПО и API
Порог входа, 1-5	3 - нужны основы Python	2 - визуальная сборка

10. Правовая и этическая оценка

Использованы публичные статистические данные World Bank и справочник стран CountriesNow. Запросы выполняются с паузами. Обход ограничений доступа не выполнялся. Ссылки на источники и условия использования приведены ниже.

11. Итоговый вывод

Собраны показатели 217 стран и экономик за три года - 651 строка. Данные объединены со справочником столиц. Проверены полнота, типы, дубликаты и значения показателей. Повторный запуск не создаёт дубликатов.

В n8n собрана выборка из 30 строк. Значения общих полей совпали с Python. Python удобен для обработки и проверок, n8n - для наглядного сценария с расписанием. Их можно совместить: n8n запускает сбор, Python обрабатывает данные.

Источники

1. World Bank API.
2. CountriesNow.
3. Исходный проект CountriesNow.
4. pandas.json_normalize.
5. n8n HTTP Request.
6. Условия использования World Bank.