Лабораторная работа № 5

Промышленный краулинг: Scrapy и n8n

Вшивков К. И., ПМИ-3-2025. Вариант 6.

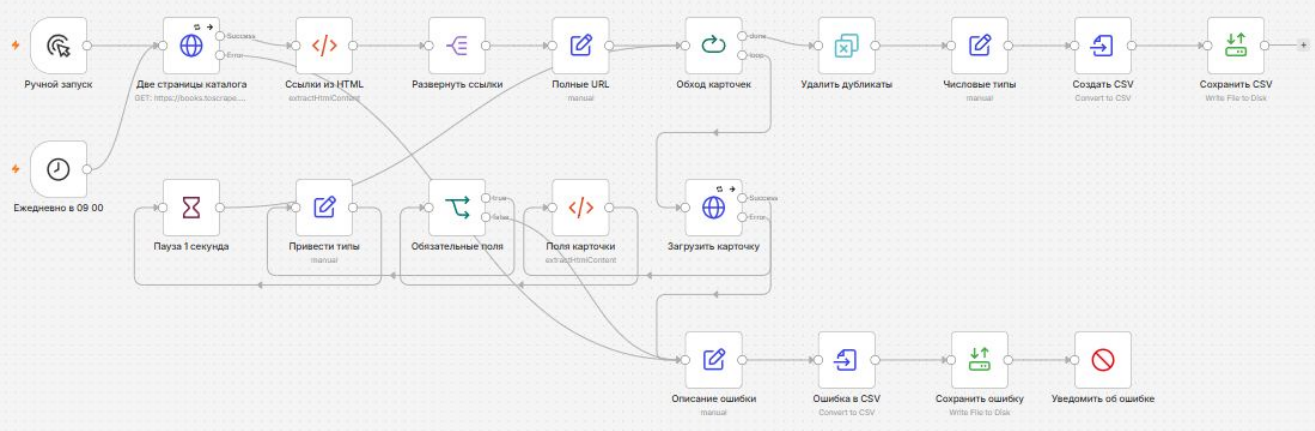
Цель: собрать данные двух сайтов в одном проекте Scrapy, проверить продолжение сбора и кэш, оценить качество и сравнить с визуальным сценарием n8n.

1. Источники и объём

Показатель	Books to Scrape	Quotes to Scrape
Списков	15	10
Детальных страниц	300 карточек книг	50 страниц авторов
Сохранено	299 книг	97 цитат
Отброшено	1 книга без описания	3 цитаты без тегов
Ключ	UPC	Автор и текст цитаты

Итого 396 записей. Пауки проходят два уровня: список и карточка. Ссылки обрабатываются response.follow, контекст передаётся через cb_kwargs. Для авторов используются повторно уже полученные сведения.

2. Схема n8n



Загружаются две страницы каталога, затем 40 карточек в цикле. Между порциями стоит Wait. После проверки и приведения типов удаляются дубли и сохраняется CSV. Сетевые узлы имеют повторы и ветку ошибки.

Schedule настроен на 09:00 по Перми. Автоматический запуск выключен до публикации workflow.

3. Структура и обработка

Файл	Назначение
lab5_crawler/spiders/books.py и quotes.py	Обход списков, карточек и страниц авторов
lab5_crawler/items.py	Поля записей двух источников
lab5_crawler/pipelines.py	Проверка → очистка → дубли → SQLite
lab5_crawler/settings.py	Задержки, ограничения, повторы и кэш
run_lab.py	Основной сбор, JOBDIR, кэш и контрольный замер

Pipeline проверяет обязательные поля и вызывает DropItem при ошибке. Цены переводятся в float, остатки и счётчики - в int, даты рождения - в ISO YYYY-MM-DD. Семантические дубли удаляются по ключам источников. Запись в две таблицы SQLite выполняется пакетами по 25, соединение открывается и закрывается вместе с пауком.

4. Ограничения и ошибки

Включён ROBOTSTXT_OBEY, задан учебный User-Agent. Одновременно разрешены четыре запроса всего и два на домен; пауза 0,5 секунды, AutoThrottle. Таймаут 25 секунд, до двух повторов для временных HTTP-ошибок. Глубина ограничена 60, сбор - 350 записями, 500 ответами или 900 секундами.

Метрика полного сбора	Результат
Время, с	291,792
Сетевых запросов	427
Тела HTML, байт	6 858 679
Получено с заголовками, байт	6 976 563
Повторных попыток	0
HTTP Books	315 ответов 200; 1 ответ 404 на robots.txt
HTTP Quotes	60 ответов 200; 50 редиректов 308; 1 ответ 404 на robots.txt

Errback записывает ошибки запросов. Итоговая статистика сохраняется при закрытии паука; причины DropItem учитываются отдельно. Кэш включается в контрольном опыте, срок хранения - 86400 секунд.

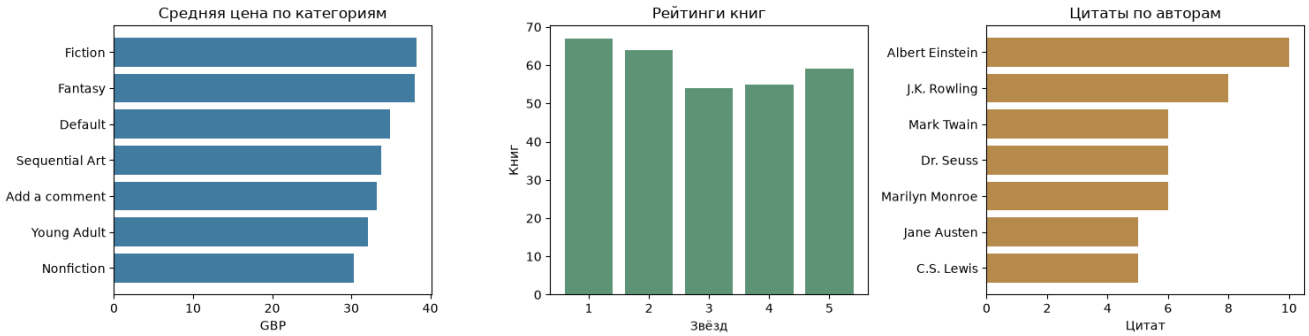
5. Продолжение сбора и кэш

Опыт	Записей	Время, с	Cache hit	Cache store
JOBDIR: до остановки	29	20.44	0	0
JOBDIR: продолжение	71	47.01	0	0
Кэш: холодный	20	13.59	0	22
Кэш: повторный	20	1.48	22	0

После продолжения получены 100 книг, повторно разобранных URL нет. В jobstate сохранены очередь и посещённые адреса до и после продолжения. Второй запуск кэша использовал 22 сохранённых ответа.

6. Качество и анализ

В базе уникальны все 299 UPC и 97 пар «автор + цитата». Обязательные поля сохранённых строк заполнены. Даты авторов разобраны по ISO; цены, остатки, рейтинги и счётчики имеют числовые типы.



Рассчитаны средние цены по категориям, распределение рейтингов и число цитат по авторам. Полнота каждого поля и подробные таблицы находятся в quality/quality_report.ipynb.

Smoke-check сравнивает текущий запуск с предыдущим: предупреждает при падении объёма более чем на 20% или доле пустых обязательных полей более 5%. Для первого запуска сохраняется база сравнения. Отдельные тесты с падением на 30% и пропусками 6% дали WARNING; нормальный пример - OK.

7. Сравнение Scrapy и n8n

Замеры от 26.10.2026 выполнены на одинаковых 40 книгах. Совпали UPC, название, цена, остаток, число отзывов, категория, описание, рейтинг и URL.

Метрика	Scrapy	n8n
Записей в одинаковой выборке	40	40
Время прогона, с	26.912	85.907
Записей в минуту	89.18	27.94
Сетевых запросов (с robots.txt)	43	42
Запросов списков и карточек	42	42
Тела HTML, МБ	0.840684	0.840684
Дедупликация запросов	Dupefilter + JOBDIR	Нет; Remove Duplicates очищает записи
Продолжение после остановки	JOBDIR, проверено	В этой схеме повторный запуск целиком
Расписание и уведомления	Нужен внешний запуск; журнал ошибок	Schedule + локальное уведомление об ошибке
Версионирование	Python-файлы и настройки в Git	Экспорт JSON в Git
Сложность поддержки 1-5 (оценка)	2: при знании Python	3: много связей и выражений

Вывод

Для разового сбора 500 товаров допустимы оба способа. Для 40 000 записей ежедневно предпочтителен Scrapy: управление запросами, JOBDIR, кэш и пакетная загрузка. Для небольшого мониторинга 100 страниц удобен n8n с расписанием; сложный разбор можно выполнять отдельным сборщиком.

Файлы и запуск

После установки requirements.txt блокнот анализирует готовую базу без Интернета. Команда python run_lab.py all повторяет сбор и опыты. Workflow импортируется из nocode/workflow.json, n8n запускается через Compose. Подробные команды находятся в README.md.

Источники

Books to Scrape

Quotes to Scrape

Scrapy: JOBDIR

Scrapy: HTTP cache