Лабораторная работа № 6

Хранение, очистка и структурирование данных

Вшивков К. И., ПМИ-3-2025. Вариант 6.

Цель: подготовить слои raw, clean и mart, проверить контракт данных, идемпотентную загрузку и историю изменений, сравнить обработку Python и n8n.

1. Источники и хранение

Используются сохранённые ответы World Bank из третьей лабораторной и данные Books to Scrape из пятой. Население и цены имеют общую схему происхождения, но анализируются отдельно. Соседние папки лабораторных для запуска не нужны.

Слой	Формат и назначение
raw	JSONL: исходные ответы, HTML и служебные поля
clean	Parquet: проверенные типы; 651 наблюдение населения и 10 книг
SQLite	Текущие данные, история изменений и отклонённые строки
mart	Три витрины Parquet; снимок с разделением по дате

В raw 1175 строк, в том числе 70 явно помеченных тестовых копий _synthetic. Поля _source, _source_url, _collected_at, _parser_version и _status описывают происхождение. Файлы raw не перезаписываются; SHA-256 сверяется до и после обработки. Пересборка из raw выполняется без сетевых запросов.

2. Сравнение форматов

Формат	Размер, байт	Чтение всех, мс	Трёх полей, мс	Ведущие нули
CSV	185099	1.059	0.75	1
JSONL	348096	6.885	7.392	1
Parquet	34063	2.839	2.134	000001

Во всех форматах один набор из 661 строки. Время - медиана пяти чтений. Parquet сохранил Decimal, UTC-дату и строковый код 000001. При автоматическом чтении CSV/JSONL деньги стали float, код - целым 1. Для текстовых форматов нужны явные типы.

JSONL удобен для дописывания raw. Parquet выбран для clean и mart из-за типов, сжатия и чтения нужных столбцов. CSV оставлен для просмотра и передачи таблиц.

3. Очистка и контракт

Этап	Вход	Выход	Изменено	Удалено
1. Нормализация текста	1175	1175	9	0
2. Бизнес-ключ	1175	1175	1175	0
3. Типизация	1175	1175	1175	0
4. Пропуски	1175	1148	0	27
5. Дубликаты	1148	671	0	477
6. Бизнес-правила и контракт	671	661	0	10

Текст нормализуется по NFKC, пробелы очищаются. Затем формируется бизнес-ключ, разбираются типы, обрабатываются пропуски, выбирается свежая запись среди повторов и проверяются бизнес-правила. Итог: 661 строка; 477 повторов и 37 невалидных строк исключены с указанием причин.

Деньги - Decimal(14,2), целые с пропусками - Int64, даты - UTC. Pydantic проверяет цену, название, UPC, остаток, рейтинг, ISO3, год, население и единицы. Используются три field_validator и один model_validator. Пять ошибочных примеров отклонены: отрицательная цена, пустое название, рейтинг 8, остаток -2 и неверная единица.

4. Метрики качества

Метрика	Значение	Зелёный	Жёлтый	Статус
Полнота обязательных	1	>= 1	>= 0.99	Зелёный
Полнота необязательных	1	>= 0.95	>= 0.8	Зелёный
Уникальность ключей	1	>= 1	>= 0.99	Зелёный
Валидность от raw	0.9617	>= 0.95	>= 0.9	Зелёный
Доля невалидных строк	0.0315	<= 0.05	<= 0.1	Зелёный
Доля удаления повторов	0.406	<= 0.1	<= 0.5	Жёлтый
Согласованность правил	1	>= 1	>= 0.99	Зелёный
Возраст данных, дней	0.2569	<= 7	<= 30	Зелёный
Изменение объёма	0	<= 0.1	<= 0.2	Зелёный

Сохранённый результат жёлтый из-за повторных доставок API. Чистые ключи уникальны. Красный статус блокирует загрузку mart; этот случай проверен на копии метрик. Давность считается от получения данных, отдельно от года наблюдения.

5. SQLite и повторная загрузка

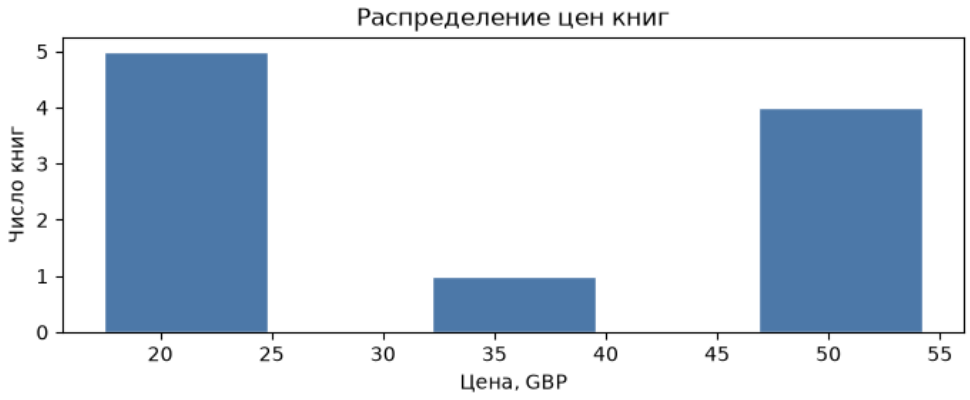
Бизнес-ключ книги строится по UPC, наблюдения населения - по ISO3, показателю и году. В схеме заданы PRIMARY KEY, NOT NULL, CHECK и индексы. Деньги хранятся целым числом сотых. Пакетный UPSERT меняет строку только при изменении её содержимого.

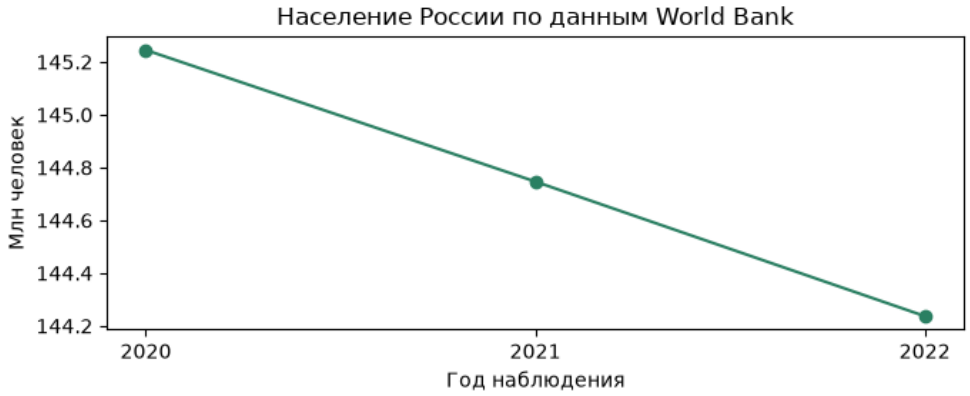
Загрузка	Строк	Изменено	Строк истории
1. Исходный	661	661	661
2. Повторный	661	0	661
3. Две тестовые цены	661	2	663

Повторная загрузка сохранила updated_at. Изменение двух цен на 1 GBP обновило две строки и добавило две версии истории. Опыт выполнен в отдельной idempotency_demo.db; рабочая warehouse.db содержит исходные значения. Ограничения БД проверены ошибочными вставками с откатом.

6. Витрины

Созданы SQL-представления by_source, population_by_year и top_books, а также их Parquet-выгрузки. Снимок разбит по дате получения: dt=2026-10-25. Проверено чтение одной партиции.





7. Обработка в n8n



Из CSV прочитаны 47 строк. После удаления повторных ключей осталось 44: 40 корректных и 4 отклонённых. Нормализуются ключ, текст, сумма, источник и URL. Контрольный запуск занял 0,848 с.

Этап	Python	n8n
Нормализация	Шесть шагов очистки	Code: преобразование полей
Дубликаты	Ключ и выбор свежей записи	Remove Duplicates
Проверки	Pydantic и бизнес-правила	Code и IF
Отбраковка	rejects.jsonl и SQLite	Отдельный CSV
Загрузка	UPSERT в SQLite	CSV; файловый узел без SQL UPSERT
История и пороги	Снимки изменений и gate_mart	В этой схеме не реализованы

Расписание настроено на 09:00 по Перми; автоматический запуск выключен до публикации workflow. Входная таблица и обе выгрузки находятся в nocode.

Вывод

Из двух источников получен чистый набор из 661 строки. Проверены очистка, типы, контракт, UPSERT, история, ограничения базы и запрет публикации при красном статусе. n8n подходит для простой обработки таблицы; полный контракт, история и контроль качества выполнены в Python.

Файлы и запуск

Код обработки: src/. Схема и загрузка базы: db/schema.sql и db/load.py. Анализ: quality_report.ipynb. Команда python -m src.rebuild --demo-db повторяет обработку и опыт с тремя загрузками. Установка, запуск блокнота и импорт n8n описаны в README.md.

Контрольные результаты сохранены 25-26.10.2026. При позднем повторном запуске метрика давности меняется: после 30 дней красный статус остановит обновление mart.

Источники

World Bank API

Books to Scrape

Pydantic: валидаторы

SQLite: UPSERT

Apache Parquet